

學號：R05546022 系級：工工所碩二 姓名：謝立成

請實做以下兩種不同 **feature** 的模型，回答第 (1) ~ (3) 題：

- (1) 抽全部 9 小時內的□染源 **feature** 的一次項(加 **bias**)
- (2) 抽全部 9 小時內 **pm2.5** 的一次項當作 **feature**(加 **bias**)

備註：

- a. **NR** 請皆設□ 0，其他的數□不要做任何更動
- b. 所有 **advanced** 的 **gradient descent** 技術(如: **adam**, **adagrad** 等) 都是可以用的

1. (2%)記錄誤差□ (**RMSE**)(根據 **kaggle public+private** 分數)，討論兩種 **feature** 的影響

| 9hr | All feature | only pm2.5 |
|---------|-------------|------------|
| Private | 7.4663 | 7.4401 |
| public | 5.3011 | 5.6272 |
| RMSE | 6.4748 | 6.5962 |

We can see that although only PM2.5 can train the public data lower, the private data is better when all feature is taken into account.


2. (1%)將 **feature** 從抽前 9 小時改成抽前 5 小時，討論其變化


| 5hr | All feature | only pm2.5 |
|---------|-------------|------------|
| Private | 7.7375 | 7.579 |
| public | 5.3782 | 5.7919 |
| RMSE | 6.6631 | 6.7449 |

Same result as above, but is poorer than that of 9 hour training

3. (1%)Regularization on all the weight with $\lambda=0.1$ 、 0.01 、 0.001 、 0.0001 ，並作圖

It appears to be little difference when λ is different





| | Regularization(λ) | public | private | RMSE |
|--------------|-----------------------------|--------|---------|--------|
| all features | 0.1 | 7.4663 | 5.301 | 6.4748 |
| | 0.01 | 7.4663 | 5.301 | 6.4748 |
| | 0.001 | 7.4663 | 5.301 | 6.4748 |
| | 0.001 | 7.4663 | 5.3011 | 6.4748 |
| only pm2.5 | 0.1 | 7.7375 | 5.3782 | 6.6631 |
| | 0.01 | 7.7375 | 5.3782 | 6.6631 |
| | 0.001 | 7.7375 | 5.3782 | 6.6631 |
| | 0.001 | 7.7375 | 5.3782 | 6.6631 |

4. (1%) 在線性回歸問題中，假設有 N 筆訓練資料，每筆訓練資料的特徵 (feature) 一向量 \mathbf{x}^n ，其標註 (label) 一存量 y^n ，模型參數一向量 \mathbf{w} (此處忽略偏權 b)，則線性回歸的損失函數 (loss function) $\sum_{n=1}^N (\hat{y}^n - y^n)^2$ 。若將所有訓練資料的特徵以矩陣 $\mathbf{X} = [\mathbf{x}^1 \mathbf{x}^2 \dots \mathbf{x}^N]^T$ 表示，所有訓練資料的標註以向量 $\mathbf{y} = [y^1 y^2 \dots y^N]^T$ 表示，請問如何以 \mathbf{X} 和 \mathbf{y} 表示可以最小化損失函數的向量 \mathbf{w} ？請寫下算式並選出正確答案。(其中 $\mathbf{X}^T \mathbf{X}$ invertible)

ANS : (c)

$$L = \sum_{n=1}^N (\mathbf{y} - \mathbf{w}^T \mathbf{X})^T (\mathbf{y} - \mathbf{w}^T \mathbf{X})$$

Minimize loss :

$$\frac{dL}{d\mathbf{w}} = 2 \times (\mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{X} \mathbf{w}) = 0$$

$$\rightarrow \hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$